

LLM İşe Alım Kararlarında Warmth ve Competence Temsillerinin Probing Yöntemiyle İncelenmesi

Emrecañ Ulu¹ ve Jorge Lastra Cerda²

¹University of Konstanz

²University of Konstanz

15 Temmuz 2026

Özet

İşe alım süreçlerindeki ayrımcılık hem insanlar hem de büyük dil modelleri üzerinde belgelenmiş olsa da bu ayrımcılığı üreten iç mekanizmalar yeterince anlaşılmış değildir. Bu çalışmada Stereotype Content Model’in warmth ve competence boyutlarının, açık ağırlıklı ve instruction-tuned dört dil modelinin (Gemma-3-12B, Gemma-3-27B, Llama-3.1-8B ve Qwen3-14B) residual stream’lerinde doğrusal yönler olarak kodlanıp kodlanmadığını ve bu temsiller doğrudan steering ile değiştirildiğinde işe alım callback önerilerini nedensel olarak değiştirip değiştirmediğini probing yöntemiyle inceliyoruz. Warmth ve competence’in dört mimarının tamamında çok büyük effect size değerleriyle doğrusal olarak ayrılabilirdiğini, yönlerin concept-level yargılarda nedensel işlev taşıdığını ve Gemma ailesinin insan sosyal algı puanlarıyla kısmen hizalanırken Llama ile Qwen’in warmth anti-alignment gösterdiğini buluyoruz. Temsilden işe alım kararına uzanan nedensel zincir kırılğan ve modele bağılıdır: concept-level düzeyde steering’e en açık model anlamlı bir mediation path göstermezken, daha büyük Gemma modeli insanlardaki ırksal callback farkını bir standard deviation’dan fazla tersine çevirmektedir. Bu sonuç, devralınmış ayrımcılıktan çok instruction-tuning kaynaklı bir overcorrection ile tutarlıdır.

Giriş

AI destekli araçlar günümüzde özgeçmişleri taramakta, adayları sıralamakta ve modern işe alım sürecinin her aşamasında callback kararlarını desteklemektedir. SHRM’nin 2025 Talent Trends araştırmasına göre ABD’deki kuruluşların yarısı işe alımı desteklemek için AI kullanmakta, yüzde 44’ü ise bu teknolojiyi özellikle özgeçmiş taraması için devreye almaktadır (Society for Human Resource Management, 2025). Bu ölçekte, model önerilerindeki her sistematik sapma işe erişimde doğrudan eşitsizliğe dönüşür.

Bu sapma varsayımsal değildir. On yıllara yayılan correspondence study’ler; ırk, ulusal köken, yaş, engellilik ve gender eksenlerinde ölçülebilir işe alım ayrımcılığı bulunduğunu göstermiştir (Bertrand ve Mullainathan, 2004; Oreopoulos, 2011; Neumark ve diğ., 2019; Correll ve diğ., 2007; Tilcsik, 2011; Ameri ve diğ., 2018). İşe alım kararı otomatikleştirmenin bu örüntüleri koruyup korumadığı ya da büyütüp büyütmediği artık güncel bir araştırma sorusudur. Büyük dil modellerine ilişkin çeşitli behavioral audit çalışmaları bunun gerçekleştiğine işaret etmektedir: Wilson ve Caliskan (2024) ve Chaturvedi ve Chaturvedi (2025), LLM’lerin özgeçmiş değerlendirmesinde bazı demografik grupları sistematik

olarak diğerlerinden üstün tuttuğunu bulurken; An ve diğ. (2024), An ve diğ. (2025) ve Gaebler ve diğ. (2024), GPT ailesinin callback önerilerinde kalıcı ırk ve gender farkları belgelemektedir. Bu çalışmalar bias’ın varlığı konusunda birleşmekte, fakat yönü ve büyüklüğü konusunda ayrışmaktadır. Hiçbiri iç mekanizmanın yerini belirleyemez; modelin neye karar verdiğini betimler, bu karara nasıl ulaştığını değil.

Mechanistic interpretability bu mekanizmayı incelemek için bir yol sunar. Word embedding araştırmaları, semantik concept’lerin yüksek boyutlu activation space içinde doğrusal yönler hâlinde kümелendiğini göstermiş (Mikolov ve diğ., 2013); linear representation hypothesis ise bu görüşü modern büyük modeller için biçimselleştirmiştir (Park ve diğ., 2024). Representation engineering (Zou ve diğ., 2023) ve activation addition (Turner ve diğ., 2023), bir modeli böyle bir yön boyunca steering ile değiştirmenin davranışı nedensel olarak değiştirdiğini göstermiş; circuit analizleri de tekil bileşenleri tanımlanabilir hesaplamalarla ilişkilendirmiştir (Olah ve diğ., 2020). Yakın zamanda Sofroniew ve diğ. (2026), Claude Sonnet’teki emotion concept’lerinin doğrusal residual-stream yönleri olarak kodlandığını ve doğrudan steering altında davranışı nedensel olarak düzenlediğini göstermiştir. Bu bulgu, representation geometry’nin sembolik word vector’lerden instruction-tuned modellerin iç activation’larına kadar uzandığına dair kanıt sunar. Biz bu

Sorumlu yazarlar: emrecañ.ulu@uni-konstanz.de; jorge.lastra-cerda@uni-konstanz.de

tekniki farklı bir construct'a uyguluyoruz.


Bu construct, Stereotype Content Model'e göre sosyal grupların algılandığı iki eksen olan warmth ve competence'tir (Fiske ve diğ., 2002). Sosyal işaretlere ilişkin warmth ve competence puanları, Kuzey Amerika'da onlarca yıla yayılan correspondence study'lerdeki insan callback oranlarını yordamaktadır (Gallo ve diğ., 2024); dolayısıyla bu eksenler LLM işe alım eşitsizlikleri için doğal bir aday mekanizmadır. Açık ağırlıklı dört modelin warmth ve competence'ı doğrusal olarak decode edilebilen residual-stream yönleri hâlinde içselleştirip içselleştirmedigini, bu yönlerin nedensel işlev taşıyıp taşımadığını ve eşleştirilmiş bir insan benchmark'ına karşı gözlemlediğimiz isim kaynaklı callback farklarına aracılık edip etmediğini soruyoruz. Bu soru, yanlış kararların sonuçlarının doğrudan ve ölçülebilir olduğu bir alanda mechanistic interpretability'yi correspondence study geleneğiyle birleştirir.

Arka Plan: Bir Dil Modelindeki Concept Nasıl Okunur?


Activation'lar ve Residual Stream. Bir transformer'daki her forward pass, hesaplamayı toplamsal residual connection'lar üzerinden biriktirir: her layer ℓ , d_{model} boyutlu bir $h_\ell \in \mathbb{R}^{d_{\text{model}}}$ state'ini okur ve $h_{\ell+1} = h_\ell + f_\ell(h_\ell)$ biçiminde güncellenmiş bir sürümünü yazar. Burada f_ℓ , ilgili layer'ın attention ve MLP sub-block çıktılarının birleşimidir. Circuit-level analizler, düşük düzeyli syntax'tan yüksek düzeyli semantic content'e kadar belirli feature'ların bu stream içinde context'ler arasında tutarlı geometric pattern'ler olarak yerleştiğini göstermiştir (Olah ve diğ., 2020). Mimarının tamamını probing ile incelemek yerine, seçilmiş tek bir depth'teki residual-stream state'ini çıkarıyor ve bu vector'ü warmth ile competence'in yönler olarak bulunduğu space kabul ediyoruz. Bu depth, Cohen's d emergence curve'lerine göre seçilen network layer'larının yaklaşık yüzde 65'ine karşılık gelir.

Yönler Olarak Concept'ler. Semantic content'in doğrusal yönler hâlinde düzenlendiği sezgisi word-embedding analogilerine dayanır (Mikolov ve diğ., 2013). *Linear representation hypothesis* (Park ve diğ., 2024), bu sezgiyi büyük transformer modelleri için biçimselleştirir: high-level feature'lar residual-stream space içindeki yönlerle karşılık gelir ve bir representation'ın bu yöne projection'ı, ilgili feature'ın ne kadar güçlü bulunduğunu ölçen bir scalar üretir. Hedef concept için böyle bir yön çıkarmak amacıyla, concept'i ifade eden metinlerden (condition A) ve etmeyen eşleştirilmiş metinlerden (condition B) residual-stream activation'ları topluyor ve mean-difference'ı hesaplıyoruz:

$$v = \bar{h}_A - \bar{h}_B. \quad (1)$$



Şekil 1: Activation space içinde yönler olarak emotion vector'ler (şematik). Her emotion, nötr bir model state'i olan h noktasından çıkan bir unit direction'a karşılık gelir. Fear uyandıran bir prompt verildiğinde residual stream, $\hat{v}_{\text{fear}}$ boyunca kayar; bu yön burada temsili d boyutlu coordinate'leriyle kodlanmıştır. Sofroniew ve diğ. (2026) temel alınmıştır; construct'ı değil, geometry'yi yeniden kullanıyoruz.



Şekil 2: Residual-stream concept geometry (şematik). Mean-difference yönü $v = \bar{h}_{\text{high}} - \bar{h}_{\text{low}}$ ile ayrılan iki story cluster (mavi ok). Kırmızı kesikli ok, marjinal bir noktayı decision boundary'nin ötesine taşıyan tek bir steering adımını, $h' = h + \alpha v$, gösterir. Gösterim ölçülmüş verilere değil, sentetik activation'lara dayanır.

$\hat{v}$ yönüne normalization uygulandığında bir concept direction elde edilir; yeni bir metnin concept score'u $\hat{v}^\top h$ olur. Cross-validated classification ve topic-holdout accuracy ile burada doğruladığımız temel iddia, bu yönün oluşturulmasında kullanılan belirli metinlerin ötesine genellenmesidir (Şek. 2).

Correlation'dan Causation'a. Mean-difference yöntemiyle çıkarılan bir yön başlangıçta correlational'dır: high ve low condition activation'larını ayırır, ancak modelin bu yönü nedensel olarak kullandığını tek

başına göstermez. Causality'yi test etmek için inference sırasında residual stream'e müdahale ediyoruz. Probe layer'da modelin iç state'ini şu ifadeyle değiştiriyoruz:

$$h' = h + \alpha \hat{v}, \quad (2)$$

Burada α , müdahalenin büyüklüğünü ve yönünü kontrol eden signed scalar'dır. Orthogonal bir control direction benzer bir değişim üretmezken modelin downstream davranışı α ile sistematik biçimde değişiyorsa, söz konusu yön modelin hesaplamalarına nedensel olarak katılmaktadır. Activation addition (Turner ve diğ., 2023) ve representation engineering (Zou ve diğ., 2023), bu yaklaşımı temellendirmiş ve çeşitli model ve hedef davranışlarda ampirik destek sağlamıştır.

Emotion-Vector Template'i. Sofroniew ve diğ. (2026), bu framework'ü Claude Sonnet'teki emotion concept'lerine uygulamıştır. Her emotion için contrastive text pair'leri oluşturmuş, residual stream'de mean-difference yönleri çıkarmış, modeli bu yönler boyunca steering ile değiştirmiş ve davranışta sistematik, yorumlanabilir değişimler gözlemlemişlerdir. Çalışma ayrıca, direction vector'lerden genel evaluative valence'ı kaldıran neutral-corpus PCA denoising prosedürünü tanıtmıştır. Methods bölümünde açıkladığımız üzere, warmth ve competence content'ini ortak narrative polarity'den ayırmak için bu adımı aynen uyguluyoruz. Geometry ve method'u yeniden kullanıyor, farklı bir construct'ı inceliyoruz. Warmth ve competence, Stereotype Content Model'den gelen social perception dimension'larıdır; emotion state'leri değildir. Bu nedenle kendi direction vector'lerimizi "emotion vector" olarak adlandırmak bir category error olur. Şek. 1, temel fikri gösterir: her emotion, residual-stream space içinde çıkarılabilen, incelenen ve model steering'inde kullanılabilen sayısal bir representation'a sahip ayrı bir yöndedir.

Neden Warmth ve Competence, Neden İşe Alım ve Hangi Veriler?

Construct. Stereotype Content Model (Fiske ve diğ., 2002), social perception'ın iki temel eksen boyunca düzenlendiğini öne sürer: algılanan intentions ve trustworthiness'ü kapsayan warmth ile algılanan ability ve effectiveness'ı kapsayan competence. Bu iki dimension birlikte, insanların social group ve individual değerlendirmelerindeki variance'ın önemli bir bölümünü açıklar (Fiske ve diğ., 2007).

İşe Alımla Bağlantı. Gallo ve diğ. (2024), kritik ampirik köprüyü sağlar. Kuzey Amerika'da yayımlanmış on correspondence study'de 787 rater tarafından 282 applicant first name için verilen 24.220 warmth ve competence rating'ini birleştiren yazarlar, algılanan warmth

ve competence'ın bu isimlerin gerçek işe alım deneylerinde aldığı callback oranlarını güvenilir biçimde yordadığını göstermektedir. Human benchmark bu nedenle nadir bir olanak sunar: probing ile incelediğimiz social perception dimension'ları ile gerçek labor market outcome'ları arasında doğrudan quantitative bir bağlantı. LLM'lere ilişkin behavioral audit'ler isim kaynaklı işe alım farklarını belgelemiştir (An ve diğ., 2024; An ve diğ., 2025; Gaebler ve diğ., 2024); fakat hiçbir model içindeki warmth ve competence representation'larının bu signal'ı taşıyıp taşımadığını test etmemiştir. Gallo ve Hausladen dataset'ini hem probe'larımız için external validity check hem de model-level disparity'leri karşılaştırmak için reference olarak kullanıyoruz.

Bu Verilerin Seçilme Nedeni. Warmth ve competence'ı doğrudan hiring prompt'larından probing ile çıkarmak, social perception dimension'larını işe alım kararının kendisiyle confound ederdi. Representation'ları izole etmek için, warmth ve competence'ı ifade eden ancak hedef construct'la karıştırılabilecek demographic identity cue'ları içermeyen metinlere ihtiyaç vardır. Pilot çalışma, bu constraint olmadan LLM ile üretilen concept story'lerin low-warmth ve low-competence condition'larına sistematik olarak erkek ve Anglo isimli protagonist'ler atadığını göstermiştir. Böyle bir örüntü, herhangi bir işe alım değerlendirmesi başlamadan demographic expectation'ları direction vector'lere yerleştirirdi. Bu nedenle 200 concept story'nin tamamında isimsiz ve gender-neutral bir protagonist bulunur; vector'ler yalnızca betimlenen behavior'dan oluşturulur. Hiring evaluation ise ayrı bir stimulus set kullanır: Gallo ve diğ. (2024) çalışmasındaki 282 applicant name, name'in değişen tek signal olması için aynı sabit application ile eşleştirilir. Bu 282 name'in 149'u aynı kaynaktaki yayımlanmış per-name callback dataset'inde de bulunur ve ABD race ile gender label'larına sahiptir; demographic disparity için benchmark comparison bu 149 name üzerinde yapılır. Her name'in crowd-sourced perception rating'i bulunduğu için, yayımlanmış callback verisi olmayanlar da dahil olmak üzere 282 name'in tamamı probe-versus-human warmth ve competence rating alignment analizinde kullanılır.

Yöntem

Story Corpus. Demographic identity'den bağımsız concept direction vector'leri oluşturmak için, dört condition'a eşit dağıtılmış 200 kısa narrative ürettik: high warmth, low warmth, high competence ve low competence (condition başına 50 story). Her biri yaklaşık 90–150 word uzunluğundaydı. Story'ler, on domain'e yayılan 50 farklı gündelik topic çevresinde yazıldı (workplace, learning, community, sport, travel ve diğerleri). Situational vocabulary'nin high ve low pole'lar arasında

dengeli olması için her topic her condition’da bir kez yer aldı. Bütün story’lerde isimsiz, gender-neutral ve third-person bir protagonist (“they”) bulunur. Bu tasarım kararı, AI ile üretilen concept story’lerde sistematik demographic skew gösteren pilot çalışmaya dayanır: low-warmth ve low-competence condition’ları büyük ölçüde erkek, Anglo isimli protagonist’lere; high condition’lar ise kadın ve demografik açıdan çeşitli protagonist’lere atanmıştı. Neutralisation olmadan direction vector’ler hedef social dimension ile birlikte demographic expectation’ları da kodlar ve incelemeyi amaçladığımız bias ile probe’u confound ederdi. Identity signal’larının tümüyle kaldırılması sayesinde her story’nin activation’ı group membership yerine betimlenen behavior tarafından belirlenir. Story’ler bir large language model tarafından üretildi ve forbidden-vocabulary violation, condition’lar arası length balance ve demographic neutrality için automated check’lerle doğrulandı. AI-generated stimulus kullanımı circularity endişesi doğurmaktadır; bu konuyu Limitations bölümünde ele alıyoruz. Mevcut 200 story’lik corpus bir pilot’tur; data collection ilerledikçe 400 story’ye genişletmeyi planlıyoruz.

Activation Extraction. Dört açık ağırlıklı instruction-tuned modelden residual-stream activation’ları çıkarmak için TransformerLens (Nanda ve Bloom, 2022) kullandık: primary model Gemma-3-12B-it (Gemma Team, 2025), within-family scale replication için Gemma-3-27B-it ve cross-architecture replication için Qwen3-14B (Yang ve diğ., 2025) ile Llama-3.1-8B-Instruct (Grattafiori ve diğ., 2024). Her modelde full layer sweep’ten elde edilen Cohen’s d emergence curve’leri temelinde seçilen ve model depth’inin yaklaşık yüzde 65’ine karşılık gelen layer’daki post-layer residual-stream state’ini kaydettik. Tab. 1, her modelin tam probe layer’ını, model width’ini ve mean residual-stream norm’unu gösterir. Her story için activation’lar prompt prefix’i atlanarak position 50 sonrasındaki token position’larında mean pooling ile birleştirildi ve story başına tek bir d_{model} boyutlu vector elde edildi. Warmth ve competence direction vector’leri daha sonra mean-difference olarak oluşturuldu: $v_W = \bar{x}_{\text{high warmth}} - \bar{x}_{\text{low warmth}}$ ve $v_C = \bar{x}_{\text{high comp.}} - \bar{x}_{\text{low comp.}}$. Cross-architecture comparison’ı mümkün kılmak için dört model de tamamen aynı condition’larda çalıştırıldı (aynı story’ler, aynı pooling rule, aynı seed 20260527).

PCA Denoising. Warmth ve competence direction vector’leri general narrative valence’ı yansıtan önemli bir ortak component paylaşır: protagonist’i olumlu betimleyen story’ler, ister warm ister competent olsun, residual stream’in benzer bir bölgesinde yer alır; negative valence’a sahip story’ler için de aynı durum geçerlidir. Conceptual content’i evaluative polarity’dan ayırmak için Sofroniew ve diğ. (2026) çalışmasının

Tablo 1: Model parameter’ları ve probe extraction setting’leri. Probe layer, seçilen/toplam layer olarak verilmiştir. $\|\bar{h}\|$, steering intervention’larının scale’ini belirleyen probe layer’daki mean residual-stream norm’dur; model activation scale’leri arasındaki orders-of-magnitude fark, normalization olmadan raw-strength comparison’larını anlamsız kılar.

Model	d_{model}	Probe layer	$\ \bar{h}\ $
Gemma-3-12B-it	3840	31/48	79,722
Gemma-3-27B-it	5376	40/62	61,576
Llama-3.1-8B-Instruct	4096	20/32	11.4
Qwen3-14B	5120	26/40	206.6

neutral-corpus denoising prosedürünü izliyoruz. Concept story’lerle length-matched (90–200 word), emotionally charged ya da violent content içermeyecek biçimde filtrelenmiş 1.500 Wikipedia giriş paragrafından oluşan neutral corpus kuruyoruz. Residual-stream activation’lar aynı layer ve pooling rule ile çıkarılır. Principal component analysis (PCA) bu neutral activation’lar üzerinde fit edilir; neutral variance’in en az yüzde 50’sini birlikte açıklayan top component’ler daha sonra iki direction vector’den de project out edilir. Gemma-3-12B’de ilk principal component tek başına neutral variance’in yüzde 56,1’ini açıklar; bu component’in çıkarılması warmth ve competence vector’leri arasındaki cosine’ı 0,749’dan 0,530’a düşürür. Gemma-3-27B’de yüzde 50 threshold’unu geçmek için 43 component gerekir (açıklanan variance yüzde 50,2) ve inter-axis cosine 0,708’den 0,487’ye düşer. Denoising sonrasında kalan cosine değerleri (sırasıyla 0,53 ve 0,49), insan rating’lerinde gözlenen gerçek warmth-competence correlation’ı ile tutarlıdır ($r \approx 0.61$; Fiske ve diğ. 2002). Bu durum residual overlap’in bir denoising failure yerine gerçek conceptual co-variation’ı yansıttığını düşündürür. Elde edilen denoised vector’ler bütün causal steering experiment’lerinde kullanılır.

Probe Validation. Her direction vector’ün validity’sini birbirini tamamlayan beş metric ile değerlendiriyoruz. (i) *5-fold cross-validated accuracy*: bir logistic regression classifier her target contrast içindeki full residual-stream representation’lar üzerinde train edilir ve accuracy beş stratified fold üzerinden average edilir. (ii) *Topic-holdout accuracy*: GroupKFold kullanan daha sıkı bir variant’tır. Belirli bir topic’e ait bütün story’ler aynı fold’a atanır; böylece probe’un yalnızca tanıdık topic’lerin görülmemiş phrasing’lerine değil, bütünüyle yeni situation’lara genellenip genellenmediği test edilir. (iii) *Cohen’s d*: direction vector’e yapılan projection’ın high ve low condition’ları arasındaki standardized mean difference, 1.000 random unit vector’den oluşan empirical null distribution ile karşılaştırılır. (iv) *Split-half cosine stability*: her condition’daki 50 story random olarak 25’er story’lik iki parçaya ayrılır; her parçadan

bir direction hesaplanır ve aralarındaki cosine raporlanır. (v) *Cross-axis classification*: fold-local standardized projection'larla warmth direction'ın competence label'ı ve tersini yordayıp yordamadığını test ederek shared evaluative content düzeyini ölçeriz. Dört modelin ortak bir cross-architecture construct üzerinde birleşip birleşmediğini sınamak için model pair'leri arasında per-story Spearman rank correlation da hesaplanır.

Causal Steering. Çıkarılan yönlerin model behavior'ı ile yalnızca correlate olmak yerine onu nedensel olarak etkileyip etkilemediğini test etmek için, probe layer'da TransformerLens hook'ları üzerinden activation steering (Turner ve diğ., 2023) uyguluyoruz. Steering strength, söz konusu layer'daki mean residual-stream norm'a göre ifade edilir; böylece activation scale'leri orders of magnitude düzeyinde farklılaşan modeller karşılaştırılabilir (Tab. 1 içindeki $\|h\|$ değerlerine bakınız). *Concept-level* evaluation'da model, held-out topic'lerde "Is the protagonist high in warmth/competence? Answer only Yes or No" sorusunu yanıtlar (topic index ile belirlenen 40 training / 10 test). Local regime, mean norm ile çarpılan $\alpha \in \{-0.10, -0.05, 0, +0.05, +0.10\}$ değerlerini kullanır. Outcome, next-token logit margin $\Delta = \text{logit(Yes)} - \text{logit(No)}$ olarak tanımlanır. *Hiring-level* evaluation'da aynı hook'lar, applicant roster'ından 60 name içeren subset üzerinde resume-evaluation prompt'ları işlenirken uygulanır. Broad sweep $\alpha \in \{\pm 0.25, \pm 0.50\}$, iki Gemma modeli için local-regime follow-up ise $\{\pm 0.05, \pm 0.10\}$ değerlerini kullanır; outcome callback logit margin'dır. Altı direction test ediyoruz: dense target direction, decoded Gemma Scope 2 SAE direction (Google DeepMind Language Model Interpretability Team, 2025), axis-specific component, shared component, opposing concept axis ve random orthogonal control. Uncertainty, paired topic bootstrap resampling ile tahmin edilir.

Hiring Evaluation. Hiring stimulus'ları, Gallo ve diğ. (2024) çalışmasındaki 282 applicant first name'i sabit bir administrative-assistant application ile birleştirir. Education, experience ve skills bütün trial'larda aynıdır; değişen tek signal name'dir. Model "would you recommend calling this candidate back for an interview? Answer with a single word: Yes or No" sorusunu yanıtlar. Outcome olan *callback margin*, next-token logit farkı $\text{logit(Yes)} - \text{logit(No)}$ olarak tanımlanır. Race ve gender label'ları modele hiçbir zaman gösterilmez; human correspondence study tasarımı yansıtacak biçimde Gallo ve diğ. (2024) coding'inden post hoc atanır (Bertrand ve Mullainathan, 2004). Hiring prompt'ından bağımsız olarak her name neutral bir carrier sentence içine yerleştirilir ve residual-stream activation'ı warmth ile competence direction'larına project edilir. Böylece elde edilen per-name probe score'lar, 787 rater'ın on source

study'deki 24.220 judgement'ından aggregate edilen human rating'lerle Spearman rank correlation kullanılarak karşılaştırılır.

Disparity ve Mediation. Group-level disparity'ler, name group'ları arasındaki mean callback margin farklarıdır (race: Black-signalling 47 ve White-signalling 180 name; gender: female 154 ve male 115 name). Farklı logit scale'lere sahip modelleri karşılaştırmak için değerler within-model callback-margin standard deviation ile standardized edilir. Human reference gap'ler, benchmark ile first name üzerinden eşleşen 149 name'deki yayımlanmış per-name callback rate'lerden aggregate edilir. İç warmth ve competence representation'larının name-group signal'ını callback decision'a taşıyıp taşımadığı, name group $\rightarrow$ probe score $\rightarrow$ callback margin path'i üzerindeki bootstrap mediation ile test edilir (5.000 resample, seed 20260527, complete data içeren $n = 269$ name, race subset $n = 227$). On altı model-by-grouping-by-probe combination'ın tamamı için indirect effect ve yüzde 95 confidence interval raporlanır.

Bulgular

Warmth ve Competence Model Aileleri Arasında Doğrusal Olarak Kodlanır. Cross-validated logistic regression probe, test edilen dört modelin tamamında hem warmth hem de competence contrast'larında yüzde 100 accuracy'ye ulaşır. Bu sonuç hem standard 5-fold cross-validation'da hem de bütün situational topic'lerin training dışında tutulduğu daha sıkı topic-holdout variant'ında geçerlidir. Perfect topic-holdout accuracy, probe'un yalnızca tanıdık topic'lerin görülmemiş phrasing'lerini değil, bütünüyle yeni social situation'lara genellenen bir yapıyı yakaladığını gösterir. Cohen's d ile ölçülen separation strength, 1.000 random unit direction'dan oluşan null distribution'a göre bütün modellerde olağanüstüdür (Şek. 3): Gemma-3-12B için warmth/competence $d = 2.70/2.83$, $z = 3.9/3.7$; Gemma-3-27B için $d = 2.95/3.27$; Qwen3-14B için $d = 8.97/9.97$, $z = 14.1/14.6$ ve Llama-3.1-8B için $d = 8.48/9.07$, $z = 15.0/15.1$ 'dir. Hiçbir modelde 1.000 random direction'dan biri target direction'ı aşmamıştır. Layer-sweep emergence curve'leri (Şek. 3), iki Gemma modelinin de peak separation'a depth'in yaklaşık yüzde 65'inde ulaştığını doğrular; bu durum Tab. 1 içindeki probe-layer seçimiyle tutarlıdır. Gemma-3-12B direction vector'lerinin split-half cosine stability'si (warmth için 0.83, competence için 0.88), bu yönlerin belirli story'lerin artefact'ı değil, condition'ların kararlı özellikleri olduğunu gösterir.

Dört model high ve low condition'ları birbirinden bağımsız biçimde ayırmakla kalmaz. Model pair'leri arasındaki per-story Spearman rank correlation'lar, hangi belirli story'lerin warm ya da cold olduğu

konusunda büyük ölçüde uzlaştıklarını gösterir (pair’ler arasında warmth için $\rho = 0.76\text{--}0.98$, competence için $0.78\text{--}0.99$). Bu bulgu, bağımsız idiosyncratic representation’lar yerine ortak bir cross-architecture construct üzerinde convergence bulunduğuna işaret eder. Denoising öncesinde warmth ve competence direction vector’leri arasındaki cosine similarity (Gemma-3-12B için 0,749; Gemma-3-27B için 0,708; Qwen3 ve Llama için 0,51–0,54) ile cross-axis classification accuracy (Gemma için 0,82–0,87; Qwen3/Llama için yaklaşık 1,00), iki yönün story’lerdeki positive-versus-negative framing’i yansıtan ortak bir evaluative component paylaştığını gösterir. PCA denoising sonrasında Gemma inter-axis cosine değeri 12B’de 0,530’a, 27B’de 0,487’ye düşer. Denoising sonrasında kalan overlap, human perception study’lerde raporlanan gerçek warmth-competence correlation’ı ile tutarlıdır ($r \approx 0.61$).


Warmth ve Competence Yönleri Nedensel İşlev Taşır. Representational description’ın ötesine geçmek için, Gemma-3-12B ve Gemma-3-27B’deki warmth ve competence direction vector’lerine held-out concept judgement task’larında activation steering uyguladık. Intervention öncesinde model, held-out topic’lerdeki doğrudan warmth/competence Yes/No sorularını yüzde 100 accuracy ile yanıtladı; baseline high–low logit-margin gap’leri 12B için 16,14/14,10 ve 27B için 25,93/23,64’tü. Dense target direction’ların local regime’de steering’i, dört model-by-axis combination’ın tamamında positive ve yaklaşık linear causal effect üretti (slope’lar: 12B warmth 27,79, $R^2 = 0.956$; 12B competence 15,11, $R^2 = 0.915$; 27B warmth 12,89, $R^2 = 0.990$; 27B competence 8,85, $R^2 = 0.826$). Bununla birlikte steering effect, iki temiz module’dan oluşan bir yorumu desteklemez: opposing concept axis de bazı condition’larda judgement’ları önemli ölçüde değiştirir. Bu sonucu specificity failure olarak görmek yerine, human benchmark’ın yapısıyla bağlantı kuran positive bir finding olarak yorumluyoruz. Gallo ve diğ. (2024), warmth ve competence rating’lerinin callback rate’leri yordayan dominant shared principal component’a indirgendığını gözlemlemiştir. Steering sonuçlarımız, aynı evaluative structure’in model içinde de temsil edildiğini ve herhangi bir dimension boyunca hareket etmenin shared positive-versus-negative appraisal’ı da değiştirdiğini düşündürür. Eşleştirilmiş Gemma-3-12B ve Gemma-3-27B Gemma Scope 2 feature’ları arasındaki cross-scale feature-profile correlation’lar (mean $r = 0.49\text{--}0.66$; beş vector type’in tamamında 500-permutation row-shuffle null değerini $p = .002$ ile aşmaktadır) representational organization’ın scale boyunca korunduğuna dair ek kanıt sağlar.

Concept-Level Steerability Modeller Arasında Belirgin Biçimde Değişir. Depolanan representation’ların nedensel olarak ne kadar verimli değiştir-

ilebildiğini karşılaştırmak için dense steering evaluation’ı, held-out concept judgement task’larında dört modelin tamamına genişlettik. Farklı baseline discrimination strength’lerin confound etkisini kaldıran bir *normalized steerability* score elde etmek amacıyla her modelin peak effect’ini ($\alpha = +0.10$) baseline high–low logit gap’ine böldük. Elde edilen ranking (Şek. 4), Gemma-3-12B’yi en steerable model olarak gösterir (warmth = 0.236, competence = 0.140). Bu modeli Qwen3-14B (warmth = 0.122, competence = 0.104), Gemma-3-27B (warmth = 0.040, competence = 0.009) ve Llama-3.1-8B (warmth = 0.029, competence = 0.024) izler. Gemma-3-27B ile Llama-3.1-8B’nin probe accuracy’lerine kıyasla çok daha düşük normalized steerability göstermesi, direction high ve low story’leri kusursuz ayırt etse bile bu modellerin warmth/competence concept’ini mean-difference direction vector ile daha az erişilebilir bir biçimde düzenlediğini gösterir. Random orthogonal control, sekiz model-by-axis cell’in altısında effect’lerin concept-specific olduğunu doğrular; -0.12 ile $+0.30$ arasındaki control effect’ler target signal’ın çok altındadır. Gemma-3-27B istisnadır: warmth için target effect control’ü yalnızca yaklaşık 1,7 kat aşar ($+1.03$ ve $+0.61$), competence için ise control effect (-3.36) signal’a ($+0.21$) doğrudan üstün gelir. Bu nedenle 27B competence steering concept-specific olarak yorumlanamaz. Bu scale’de eşit energy’ye sahip herhangi bir unit-norm linear push, target direction’ı bastıracak kadar residual stream’i perturbe eder.

Modelin İç Probe Score’ları Human Social Perception’ı Mimariler Arasında Eşit Olmayan Biçimde İzler. Hiring outcome’ları üzerindeki causal effect’leri test etmeden önce, her modelin iç probe score’larının Gallo ve diğ. (2024) çalışmasındaki human social perception rating’lerini ne ölçüde yansıttığını belirliyoruz. 282 applicant name’in her biri için probe layer’daki residual-stream activation’ı çıkarıyor ve warmth ile competence direction vector’lerine project ediyoruz. Gemma ailesi human rating’lerle positive alignment gösterir: Gemma-3-12B için Spearman $\rho = +0.366$ (warmth) ve $\rho = +0.239$ (competence); Gemma-3-27B için $\rho = +0.396$ ve $\rho = +0.272$ (tümünde $p < .001$). İnsanların daha warm ya da competent algıladığı group’larla ilişkilendirilen name’ler Gemma ailesinde de içsel olarak bu şekilde temsil edilir ve scale bu alignment’ı bir miktar iyileştirir. Gemma dışındaki iki model belirgin biçimde farklıdır. Llama-3.1-8B warmth üzerinde anti-alignment gösterir ($\rho = -0.300$, $p < .001$); competence correlation’ı anlamlı değildir ($\rho = -0.063$, $p = .29$). Qwen3-14B de warmth üzerinde anti-alignment gösterirken ($\rho = -0.193$, $p = .001$), competence üzerinde güçlü biçimde hizalanır ($\rho = +0.465$, $p < .001$). Bu warmth anti-alignment arbitrary noise’dan kaynaklanmaz: Gemma ile Llama arasındaki cross-model story-level agreement (warmth için

Warmth and competence representations emerge with depth
(topic-holdout CV = 1.00 at every layer; four open-weights models)




Şekil 3: Warmth ve competence yönleri depth boyunca güçlü biçimde ortaya çıkar. Dört açık ağırlıklı modelde layer-wise concept separation ve warmth-competence geometry.

$\rho = 0.768$) ve Gemma ile Qwen arasındaki agreement (warmth için $\rho = 0.760$), dört modelin de story’lerin relative warmth ordering’i konusunda uzlaştığını doğrular. Anti-alignment, modellerin activation space içinde paylaştığı direction’ın human warmth scale’e göre sistematik olarak ters olduğunu gösterir: bu iki mimari için modellerin “high warmth” pole olarak temsil ettiği nokta, human warmth rating’lerinin low end’ine karşılık gelir. Bu inversion’ı instruction tuning ve reinforcement learning from human feedback’e bağlıyoruz. Fine-tuning objective, raw pretraining text içinde stereotypically high warmth ile ilişkilendirilen social signal’ların aligned model representation’larında suppress ya da invert edilmesine yol açacak şekilde warmth axis’i yeniden yapılandırmış olabilir. Gemma-3-12B’de iç warmth ve competence probe score’ları, modelin baseline callback margin’ını human rating’lerle aynı yönde yordamaktadır ($\rho = +0.139$, $p = .084$; $\rho = +0.145$, $p = .067$). Gemma-3-27B’de bu association tersine döner: modelin içsel olarak daha warm veya competent temsil ettiği name’ler daha düşük callback margin alır (sırasıyla $\rho = -0.160$ ve -0.156), yani 12B pattern’ının tersi görülür. 27B’deki bu reversal, belirgin biçimde farklı bir baseline response regime ile çıkarılır: 27B model implied $P(\text{Yes}) = 0.760$ oranında callback önerirken 12B’de bu oran 0,452’dir.

Warmth ve Competence Steering Callback Önerilerini Nedensel Olarak Değiştirir. Warmth ve competence representation’larının doğrudan manipulation’ının modelin hiring-callback decision’ını değiştirip değiştirmediğini test etmek için, Gallo ve diğ. (2024) rated name set’inden alınan 60 applicant name üzerinde resume evaluation sırasında activation steering uyguladık. Gemma-3-12B’nin baseline callback margin’ı

-0.194 ($SD = 0.130$), implied $P(\text{Yes}) = 0.452$ değerine karşılık geliyordu. Local steering regime’de warmth’ü $\alpha = +0.05$ düzeyinde artırmak $+1.177$ ($SE = 0.018$), $\alpha = +0.10$ düzeyinde artırmak ise $+2.369$ ($SE = 0.017$) mean shift üretti. Bu, callback margin üzerinde büyük ve yaklaşık linear positive effect’tir. 12B competence direction daha karmaşık bir pattern gösterir: negative steering margin’ı baskılar ($\alpha = -0.05 \rightarrow -1.515$), positive steering ise yalnızca modest increase üretir ($\alpha = +0.10 \rightarrow +0.231$). Dolayısıyla competence direction’ın bu scale’deki hiring decision üzerinde symmetric causal effect’i yoktur. Gemma-3-27B’de causal evaluation’ın replication’ı, warmth için qualitatively different bir pattern ortaya çıkarır. $\alpha = +0.05$ düzeyindeki mean callback shift $+1.973$ ile 12B effect’ine yakındır; ancak $\alpha = +0.10$ düzeyinde effect -2.658 ’e çöker. Steering strength’teki artış effect direction’ı büyütme yerine tersine çevirir. Bu non-monotone response, simple ceiling saturation açıklamasını dışlar; ceiling effect plateau üretirdi, sign reversal değil. Ayrıca 27B baseline rate ($P(\text{Yes}) = 0.760$) upward shift için yeterli headroom bırakır. Gemma-3-27B’deki warmth representation bu nedenle causal steering’in beklenen effect’i ürettiği dar bir window’a sahiptir; bu window’un ötesinde representational intervention decision process’i non-linear biçimde bozar. Broad regime’de değerlendirilen cross-architecture iki model bu uçların arasında yer alır: Suite’teki en düşük concept-level steerability’ye rağmen Llama-3.1-8B her iki axis’te moderate ve monotonic response verir (warmth $\Delta = +3.17$, competence $\Delta = +2.17$, $\alpha = +0.50$). Qwen3-14B ise strength arttıkça azalan weak warmth effect’ler ($+0.79$ at $+0.25$, $+0.60$ at $+0.50$) ve near-zero competence effect’ler gösterir. Altı steering direction’ın tamamı için four-model




Şekil 4: Concept-level steerability mimariler arasında değişir. Her modelin baseline high-low concept gap'ine göre normalized edilen dense steering effect'ler, farklı logit scale'lere sahip modellerin steerability düzeylerini karşılaştırmayı sağlar.

dose-response curve ve signal-versus-control comparison'lar Şek. 5 ile Şek. 6 içinde sunulmuştur.

Model Callback Disparity'leri ve Human Benchmark. Model hiring recommendation'larındaki demographic parity'yi human correspondence-study outcome'larına göre değerlendirmek için 282-name stimulus set'i, Gallo ve diğ. (2024) çalışmasındaki yayımlanmış callback benchmark'a first-name match üzerinden bağladık. 282 name'in 149'u eşleştirdi: 9 Black Female, 9 Black Male, 84 White Female ve 47 White Male. Human benchmark, klasik audit-study pattern'ını gösterir: White name'ler Black name'lerden belirgin ölçüde daha yüksek callback rate alır (race gap = -0.085 , White lehine); male name'ler de female name'lerden biraz daha yüksek rate alır (gender gap = -0.037 , Male lehine). Gemma-3-27B'de race gap human benchmark'a göre ters ve büyüktür: Black-signalling name'lerin callback margin'ını White-signalling name'lerden $+0.486$ raw logit unit daha yüksektir; bu değer $+1.18$ within-model standard deviation'a eşittir (Şek. 7). 27B'deki gender gap -0.211 raw logit unit'tir (-0.51 SD); human direction'ı (Female < Male) yeniden üretmekle birlikte human reference'tan daha büyüktür. Bu sonuçlar büyük Gemma modelinin human racial discrimination pattern'ını over-correct ettiğini gösterir: Black-signalling name'lere empirical record'un tersi yönde, büyük ve sistematik bir advantage verirken gender gap direction'ı korur. Pattern, reinforcement learning from human feedback'in racial association'ları öylesine güçlü düzeltmiş olmasıyla tutarlıdır ki ortaya çıkan calibration, human outcome'ların empirical distribution'ını bir standard deviation'dan fazla aşmıştır. Gemma-3-12B'de callback-margin variance group-level disparity'leri güvenilir biçimde saptamak

için çok düşüktür (SD = 0.14, 0.125 logit grid üzerinde yedi unique value); bu modelin R4 sonuçları Limitations bölümünde açıklanmaktadır. Matched 149 name üzerinde modelin kendi probe score'larından callback margin'ı yordayan exploratory ordinary least-squares regression, warmth'ün 12B'de causal direction ile hizalandığını (Pearson $r = +0.376$, $p < .001$), 27B'de ise tersine döndüğünü gösterir ($r = -0.266$, $p = .001$; $R^2 = 0.088$). Bu bulgu yukarıda belgelenen reversed baseline association ile tutarlıdır. Llama-3.1-8B ve Qwen3-14B de Black-signalling name'leri üstün tutar, ancak farklar daha küçüktür (within-model SD cinsinden race gap sırasıyla $+0.40$ ve $+0.16$). İki model de female name'lere male name'lerden daha yüksek margin verir ($+0.45$ ve $+0.89$ SD) ve human gender direction'a karşı çıkar. Güvenilir margin variance'a sahip üç modelin tamamı name'leri implied race ve gender'a göre farklı işler. Hiçbiri human race direction'ı yeniden üretmez; human gender direction'ı yalnızca Gemma-3-27B yeniden üretir. Dolayısıyla disparity pattern, kararlı biçimde devralınmış bir bias değil, architecture ve scale'e bağlı bir yeniden düzenlemedir.

Representation'lar, Steering'in En Zayıf Olduğu Yerde Disparity'ye Aracılık Eder. Name group $\rightarrow$ probe score $\rightarrow$ callback margin path'i üzerindeki bootstrap mediation, steering'den farklı bir soruyu yanıtlar: external push'ın decision'ı değiştirip değiştirmediğini değil, modelin bir name'e ilişkin spontaneous warmth veya competence representation'ının demographic signal'ı callback outcome'a taşıyıp taşımadığını sorar. On altı indirect effect'ten beşinin yüzde 95 interval'i zero'yu dışlar (Şek. 8). Llama-3.1-8B'de race disparity warmth üzerinden mediate edilir (IE = $+0.190$,



Şekil 5: Activation steering işe alım callback önerilerini değiştirir. Hiring evaluation setting’inde warmth ve competence steering’e verilen callback-margin response’ları.

yüzde 95 CI $[+0.111, +0.292]$) ve competence üzerinden daha zayıf bir mediation görülür $(+0.040, [+0.004, +0.090])$. Qwen3-14B’de race, warmth üzerinden positive $(+0.081)$, competence üzerinden negative (-0.132) mediate edilir; gender ise competence üzerinden positive mediate edilir $(+0.076)$. İki Gemma modeli için sekiz testin tamamı non-significant’tır. On altı test multiple-comparison correction olmadan raporlanmıştır; yalnızca Llama race-warmth path konservatif Bonferroni threshold’unu ($\alpha = 0.05/16$) geçer. Bu nedenle daha küçük significant effect’ler suggestive olarak okunmalıdır. Steerability ranking ile birlikte bu sonuçlar bir *steerability paradox* oluşturur: Suite’teki en steerable model olan Gemma-3-12B (normalized warmth steerability 0.236) significant mediation path göstermezken, en az steerable model Llama-3.1-8B (0.029) en güçlü path’i gösterir. Bir representation’ı external push ile değiştirme kapasitesi, o representation’ın downstream decision’ı doğal olarak yönetip yönetmediğini yordamamaktadır. Steering intervention’a causal sensitivity’yi, mediation ise natural activation’ın outcome’a taşınıp taşınmadığını ölçer; bu iki ölçüm architecture’lar arasında dissociate olur.


Tartışma ve Sonuç

İnsanlar tarafından üretilmiş text üzerinde train edilen large language model’lerin warmth ve competence’i içeriden çıkarılabilir representation’lar olarak kodlaması bir açıdan şaşırtıcı değildir; bu modeller, warmth ve competence’in social perception’ı şekillendirdiği aynı text’lerdeki pattern’ları damıtır. Mevcut sonuçların ampirik olarak ortaya koyduğu nokta, bu encoding’in linear, geometrically stable, concept level’da causally func-


tional ve bağımsız laboratory’lerde geliştirilmiş mimari açıdan farklı modeller arasında shared olmasıdır. Bu özelliklerin her biri önem taşır: linearity, representation’ı lightweight probe ve steering intervention’larına erişilebilir kılar; causal functionality, representation’ın warmth ve competence’a ilişkin explicit judgement’lara katıldığını gösterir; cross-architecture convergence ise finding’in tek bir design’a özgü olmaktan çok training data ve language modelling objective’lerinin bir özelliğini yansıttığını düşündürür.

Gemma-3-12B ile Gemma-3-27B arasındaki scale comparison, bu görünümü öğretici biçimde karmaşıktır. İki model de warmth ve competence’i karşılaştırılabilir precision ile kodlar; 27B modelinin probe score’ları human warmth ve competence rating’leriyle biraz daha güçlü correlate olur. Buna karşılık concept representation’dan hiring decision’a uzanan causal chain iki model arasında keskin biçimde ayrışır. 12B’de warmth representation’ı artırmak callback inclination’da büyük ve yaklaşık linear bir artış üretir ($\alpha = +0.10$ düzeyinde $+2.37$ logit unit’e kadar). 27B’de eşdeğer intervention düşük strength’te modest positive shift üretir ($\alpha = +0.05$ düzeyinde $+1.97$), ancak biraz daha yüksek strength’te büyük negative shift’e çöker ($\alpha = +0.10$ düzeyinde -2.66). Bu non-monotone response saturation değildir: 27B baseline zaten $P(\text{Yes}) = 0.76$ düzeyindedir ve upward movement için alan bırakır; response plateau değil sign reversal’dır. Daha plausible açıklama, 27B decision layer’ın birbiriyle etkileşen birden çok representation tarafından organize edilmesidir. Concept direction dar bir window’un ötesinde amplify edildiğinde bu etkileşimleri güçlendirmek yerine bozmaya başlar.

Cross-model steerability analysis ile bağlantılı başka bir puzzle ortaya çıkar. Gemma-3-12B en yüksek con-



Şekil 6: Modeller arasında dense steering dose-response. Dört açık ağırlıklı modelde warmth ve competence direction’ları için concept-level dose-response curve’leri.



Şekil 7: Human benchmark’a göre model callback disparity’leri. Model evaluation’lardaki race ve gender callback-margin gap’lerinin correspondence-study benchmark ile karşılaştırılması.

cept steerability değerine sahiptir (normalized warmth steerability = 0.236), fakat significant bir hiring-level mediation path göstermez. Llama-3.1-8B en düşük concept steerability değerine sahiptir (normalized warmth steerability = 0.029) ve en güçlü hiring-level indirect effect’i gösterir (bootstrap IE = +0.190). Bu steerability paradox, bir modelin representation’larını linear probing yoluyla değiştirme kapasitesinin, bu representation’ların downstream decision’ı nedensel olarak yönettiği anlamına gelmediğini gösterir. Representation’ların en temiz biçimde izole edilebildiği modeller, decision process’in steering target’ı bypass eden parallel mechanism’lar üzerinden çalıştığı modeller olabilir.

Llama-3.1-8B ve Qwen3-14B’de gözlenen warmth anti-alignment ek bir complexity katmanını oluşturur. Yüksek cross-model story agreement’a rağmen (Gemma

ile diğer iki model arasında per-story Spearman $\rho \approx 0.76-0.77$), Llama ve Qwen’in activation space içinde “high warmth” olarak düzenlediği direction, human warmth rating’leriyle negative correlate olur (sırasıyla $\rho = -0.300$ ve -0.193). Modeller story’lerin aynı relative ordering’i üzerinde birleşir, fakat bu ortak ordering human scale’e göre terstir. Bunu, instruction tuning’in bu architecture’lardaki warmth axis’i yeniden yapılandığına dair kanıt olarak yorumluyoruz. Reinforcement learning from human feedback, stereotypically warm social group’larla ilişkilendirilen representation’ları, original pretraining warmth axis’iyle bağlantıyı tersine çevirecek biçimde ayarlamış olabilir.

Gemma-3-27B’deki demographic disparity sonuçları bu representational reorganization’ın pratik sonucunu gösterir. Model, Black-signalling name’lere White-


signalling name'lere göre güçlü bir advantage sağlar (+1.18 SD) ve klasik correspondence-study finding'ini doğrudan tersine çevirir. Buna karşılık gender gap direction human pattern'ı yeniden üretir. Race ve gender arasındaki asymmetry, instruction tuning'ın farklı demographic axis'lere farklı correction'lar uyguladığını düşündürür. Ortaya çıkan model overall daha equitable değil, farklı biçimde inequitable'dır: racial hierarchy ortadan kalkmak yerine tersine dönmüş ve original human disparity'den çok daha büyük bir magnitude'a ulaşmıştır. Bu finding, outcome-level bias mitigation'ın temel bir sınırlılığına işaret eder. Representational substrate anlaşılmadan behavioral output'ları düzeltmek, underlying imbalance'ı kaldırmak yerine başka bir yöne kaydırabilir.

Sonuçlar birlikte değerlendirildiğinde LLM'lerin, explicit bir design choice olmaksızın human-generated text üzerinde training yoluyla SCM'ye geniş ölçüde benzeyen bir social perception structure'ı içselleştirdiği görülür. Bununla birlikte bu iç structure ile actual hiring decision arasındaki bağlantı basit ya da modeller arasında tutarlı değildir. Bu finding, bias auditing için methodological bir sonuç doğurur: internal representation'ları probing ile incelemek ve output disparity'lerini ölçmek birbirini tamamlar, ancak birbirinin yerini tutmaz; bir metric'te iyi performans gösteren model diğerinde aynı sonucu vermeyebilir. Çalışma ayrıca, output'ları sonradan filter etmek yerine representation'a müdahale ederek problemi kaynağında ele alma yolu açmakta ve mechanistic interpretability'nin computational tool'larını social science'taki correspondence-study geleneğiyle birleştiren bir methodological template sunmaktadır.

Sınırlılıklar. Concept story corpus'un bir large language model tarafından üretilmiş olması, language model representation'larını probing ile inceleyen bir çalışma için circularity endişesi doğurur. Bununla birlikte generating model (Claude, Anthropic) ile probing uygulanan modeller (Gemma, Qwen, Llama) farklı organization ve architecture'lardan gelir; dolayısıyla warmth/competence contrast'ları shared generator tarafından trivially yeniden üretilmez. Yine de AI-generated stimulus'ların model aileleri arasında probe accuracy'yi yükselten ortak stylistic property'lere sahip olma olasılığı tümüyle dışlanamaz; human-authored veya template-based stimulus'larla replication yapılması yararlı olacaktır. Mevcut 200 story'lik corpus, 50 topic'i kapsayan bir pilot'tur; planlanan 400 story'lik expansion, per-condition sample size ve topic diversity'yi artıracaktır. Probe-to-human validation correlation'ları moderate düzeydedir (12B ve 27B için warmth $\rho = +0.366$ ve $+0.396$; competence $\rho = +0.239$ ve $+0.272$). Bu değerler, modelin internal probe'larının human social perception'ı birebir yeniden üretmek yerine onun bir component'ini yakaladığını gösterir. Llama-3.1-8B ($\rho = -0.300$) ve Qwen3-14B'deki ($\rho = -0.193$) warmth

anti-alignment, bu modellerde mean-difference direction'ın human warmth scale'e göre sistematik biçimde ters bir construct'ı yakaladığı anlamına gelir; sonuçlar bu inversion dikkate alınarak yorumlanmalıdır. Hiring level'daki causal warmth steering effect 12B'de positive ve güçlü, 27B'de ise non-monotone ve kırıkandır. Bu nedenle causal claim, qualification olmadan scale boyunca genellenemez. Model output logit'lerindeki bf16 precision nedeniyle callback margin'lar 0.125-unit grid üzerinde quantized edilmiştir; bu quantization bf16 inference'a özgüdür ve float32 subtraction ile çözülmez. Gemma-3-12B'de callback-margin standard deviation 0,14 ve unique value sayısı yalnızca yedidir. Bu nedenle 12B'deki group-level disparity estimate'leri güvenilir değildir ve 12B R4 sonuçları empirical finding olarak cite edilmemelidir. Gemma-3-27B'de daha büyük variance (SD = 0.41, 18 unique value), yaklaşık 0,5 SD büyüklüğündeki group gap'lerin saptanmasını mümkün kılar; ancak grid structure raporlanan bütün gap magnitude'larına discrete step'ler ekler. On altı mediation test, multiple comparison correction olmadan sunulmuştur; yalnızca Llama race-warmth indirect effect Bonferroni-corrected threshold'u geçer. Daha küçük significant path'ler doğrulanmış değil suggestive kabul edilmelidir. Hiring prompt gerçek dünyadaki screening context'lerine göre basitleştirilmiştir (tek role, sabit qualification); daha zengin evaluation setting'lerinde veya farklı job type'larda sonuçlar değişebilir. Son olarak, Gemma-3'te Qwen3 ve Llama-3.1'e kıyasla bütün network depth'lerinde gözlenen yüksek warmth/competence vector cosine'ın architectural kaynağı açık bir soru olarak kalmaktadır.

Gelecek Çalışmalar. İlk adım, sonuçların administrative assistant role'ünün ötesine genellenip genellenmediğini test etmek için hiring stimulus'larını farklı job role'lerine genişletmektir. Burada Gemma-3 üzerinde gerçekleştirilen SAE decomposition, Llama Scope sparse autoencoder'ları (He ve diğ., 2024) kullanılarak Llama-3.1'e genişletilebilir ve feature level'da model-family comparison yapılabilir. Concept probe'larının human-authored warmth/competence dataset ile validation'ı, AI-generated stimulus'larla ilişkili circularity endişesini ele alacaktır. Social-science tarafında hiring stimulus'larını name'lerin ötesinde category-level signal'lara (age, disability, religion) genişletmek, benchmark comparison'ın scope'unu büyütür ve representational account'ın race ile gender dışında genellenip genellenmediğini test eder. Bu finding'leri practical debiasing intervention'larına dönüştürmek ve adversarial prompting'e karşı robustness'larını değerlendirmek applied work için doğal bir sonraki adımdır.



Şekil 8: Name-group callback disparity'lerinin warmth ve competence probe score'ları üzerinden bootstrap mediation'ı. Name group → probe score → callback margin path'i için yüzde 95 confidence interval içeren indirect effect'ler; dolu marker'lar zero'yu dışlayan interval'leri gösterir.

Kaynakça

- Ameri, Mason et al. (2018). “The Disability Employment Puzzle: A Field Experiment on Employer Hiring Behavior”. In: *ILR Review* 71.2, pp. 329–364. DOI: 10.1177/0019793917717474.
- An, Haozhe et al. (2024). *Do Large Language Models Discriminate in Hiring Decisions on the Basis of Race, Ethnicity, and Gender?* DOI: 10.48550/arXiv.2406.10486. arXiv: 2406.10486 [cs.CL].
- An, Jiafu et al. (2025). “Measuring gender and racial biases in large language models: Intersectional evidence from automated resume evaluation”. In: *PNAS Nexus* 4.3, pgaf089. ISSN: 2752-6542. DOI: 10.1093/pnasnexus/pgaf089. URL: <https://doi.org/10.1093/pnasnexus/pgaf089>.
- Bertrand, Marianne and Sendhil Mullainathan (2004). “Are Emily and Greg more employable than Lakisha and Jamal? A field experiment on labor market discrimination”. In: *American economic review* 94.4, pp. 991–1013.
- Chaturvedi, Sugat and Rochana Chaturvedi (2025). *Who Gets the Callback? Generative AI and Gender Bias*. arXiv: 2504.21400 [econ.GN].
- Correll, Shelley J., Stephen Benard, and In Paik (2007). “Getting a Job: Is There a Motherhood Penalty?” In: *American Journal of Sociology* 112.5, pp. 1297–1338. DOI: 10.1086/511799.
- Fiske, Susan T., Amy J. C. Cuddy, and Peter Glick (2007). “Universal Dimensions of Social Cognition: Warmth and Competence”. In: *Trends in Cognitive Sciences* 11.2, pp. 77–83. DOI: 10.1016/j.tics.2006.11.005.
- Fiske, Susan T. et al. (2002). “A Model of (Often Mixed) Stereotype Content: Competence and Warmth Respectively Follow from Perceived Status and Competition”. In: *Journal of Personality and Social Psychology* 82.6, pp. 878–902. DOI: 10.1037/0022-3514.82.6.878.
- Gaebler, Johann D. et al. (2024). “Auditing Large Language Models for Race and Gender Disparities: Implications for AI-Based Hiring”. In: *Socius* 11. DOI: 10.1177/23794607251320229.
- Gallo, Marcos et al. (2024). “Perceived Warmth and Competence Predict Callback Rates in Meta-Analyzed North American Labor Market Experiments”. In: *PLOS ONE* 19.7, e0304723. DOI: 10.1371/journal.pone.0304723.
- Gemma Team (2025). *Gemma 3 Technical Report*. arXiv: 2503.19786 [cs.CL]. URL: <https://arxiv.org/abs/2503.19786>.
- Google DeepMind Language Model Interpretability Team (2025). *Gemma Scope 2: Helping the AI Safety Community Deepen Understanding of Complex Language Model Behavior*. Google DeepMind Blog.
- Grattafiori, Aaron et al. (2024). *The Llama 3 Herd of Models*. arXiv: 2407.21783 [cs.AI]. URL: <https://arxiv.org/abs/2407.21783>.
- He, Zhengfu et al. (2024). *Llama Scope: Extracting Millions of Features from Llama-3.1-8B with Sparse Autoencoders*. arXiv: 2410.20526 [cs.CL]. URL: <https://arxiv.org/abs/2410.20526>.
- Mikolov, Tomas et al. (2013). *Efficient Estimation of Word Representations in Vector Space*. arXiv: 1301.3781 [cs.CL].
- Nanda, Neel and Joseph Bloom (2022). *TransformerLens*. <https://github.com/TransformerLensOrg/TransformerLens>.
- Neumark, David, Ian Burn, and Patrick Button (2019). “Is It Harder for Older Workers to Find Jobs? New and Improved Evidence from a Field Experiment”. In: *Journal of Political Economy* 127.2, pp. 922–970. DOI: 10.1086/701029.
- Olah, Chris et al. (2020). “Zoom In: An Introduction to Circuits”. In: *Distill*. DOI: 10.23915/distill.00024.001.
- Oreopoulos, Philip (2011). “Why Do Skilled Immigrants Struggle in the Labor Market? A Field Experiment with Thirteen Thousand Resumes”. In: *American Economic Journal: Economic Policy* 3.4, pp. 148–171. DOI: 10.1257/pol.3.4.148.
- Park, Kiho, Yo Joong Choe, and Victor Veitch (2024). *Linear Representation Hypothesis and the Geometry of Large Language Models*. arXiv: 2311.03658 [cs.LG].
- Society for Human Resource Management (2025). *2025 Talent Trends: The Role of AI in HR Continues to Expand*. SHRM Research Report. URL: <https://www.shrm.org/topics-tools/research/2025-talent-trends/ai-in-hr>.
- Sofroniew, Nicholas et al. (2026). *Emotion Concepts and Their Function in a Large Language Model*. DOI: 10.48550/arXiv.2604.07729. arXiv: 2604.07729 [cs.CL].
- Tilcsik, András (2011). “Pride and Prejudice: Employment Discrimination Against Openly Gay Men in the United States”. In: *American Journal of Sociology* 117.2, pp. 586–626. DOI: 10.1086/661653.
- Turner, Alexander Matt et al. (2023). *Activation Adaption: Steering Language Models Without Optimization*. arXiv: 2308.10248 [cs.LG].
- Wilson, Kyra and Aylin Caliskan (2024). “Gender, Race, and Intersectional Bias in Resume Screening via Language Model Retrieval”. In: *Proceedings of the AAAI/ACM Conference on AI, Ethics, and Society*. Vol. 7, pp. 1578–1590. DOI: 10.1609/aies.v7i1.31748.
- Yang, An et al. (2025). *Qwen3 Technical Report*. arXiv: 2505.09388 [cs.CL]. URL: <https://arxiv.org/abs/2505.09388>.
- Zou, Andy et al. (2023). *Representation Engineering: A Top-Down Approach to AI Transparency*. arXiv: 2310.01405 [cs.LG].

Ek Materyaller

Yöntem Ayrıntıları

Ek Bulgular